

Fakulta elektrotechniky
a informatiky

Detekcia potravinových rizík

SemEval-2025 Task 9

Nikita Suhak · Denys Klym

Problém a cieľ

V tejto úlohe riešime problém potravinových rizík na základe zadania SemEval-2025 Task 9, kde úlohou je klasifikácia textu a spočíva v tom, aby sme model naučili rozpoznávať typ rizika a kategóriu produktu, kvôli ktorej riziko vzniklo.

Podrobný popis cieľu

Vstup: krátke správy o stiahnutí nebezpečných potravín z trhu.
Výstup: kategória rizika a kategória produktu.
Cieľ: urýchliť identifikáciu potravinových hrozieb.

- Prvý model predpovedá kategóriu rizika.
- Druhý model predpovedá kategóriu produktu.

Cieľom je preskúmať existujúce riešenia, vytvoriť základné riešenie, uskutočniť experimenty s existujúcimi riešeniami a porovnať výsledky

Dataset

6 644 záznamov celkovo
5 082 trénovacích · 565 validačných · 997 testovacích
10 kategórií rizík · 22 kategórií produktov
Výzva: nevyvážené zastúpenie kategórií.

Navrhnuté riešenie

Text → TF-IDF → Logistic Regression → Predikcia
Dva samostatné klasifikátory: riziko a produkt.
Použité knižnice: pandas, NumPy, scikit-learn.

Príprava dát a TF-IDF

Vstup: atribút title z CSV súboru.

Cieľové štítky: hazard-category a product-category.

Tréning: fit_transform() vytvorí slovník a textové vektory.

Validácia a test: transform() použije rovnaký slovník.

Validačné dáta tak neovplyvňujú tvorbu slovníka.

Po úvodnom delení 4 062 / 1 020 sme použili oficiálne dáta.

Dialše možne riešenia

- BERT

BERT je model založený na architektúre Transformer. Dokáže lepšie pracovať s kontextom slov vo vetách.

- CICLe

CICLe je pokročilejší prístup využívajúci veľké jazykové modely a metódu conformal prediction. Jeho cieľom je zlepšiť klasifikáciu aj pri kategóriách s menším počtom príkladov.

Experimenty

Hodnotenie: Accuracy a Macro F1
Skúšané: unigramy, bigramy, sublinear_tf, class_weight a parameter C.
Vyváženie tried zlepšilo Macro F1.
Finálne: riziko C=1,0; produkt C=10,0.

Vplyv vyvažovania tried

Unigramy, sublinear_tf=True a class_weight="balanced".

Macro F1	Základný model	Po úprave
Riziká	0,4516	0,6009
Produkty	0,3886	0,5082

Macro F1 sa zlepšilo pri oboch klasifikátoroch.

Presnosť klasifikácie produktov pritom mierne klesla.

Priebežné experimenty pred finálnym testovaním.

Výber parametra C

Porovnanie pri class_weight="balanced".

C	Riziká: Macro F1	Produkty: Macro F1
0,1	0,5539	0,3761
1,0	0,6009	0,5082
10,0	0,5945	0,5373

Zvolené C: riziká 1,0 a produkty 10,0. max_iter=1000.

Priebežné experimenty pred finálnym testovaním.

Výsledky testovania

Riziká: Accuracy 0,8175 · Macro F1 0,5827
Produkty: Accuracy 0,7513 · Macro F1 0,6676
Conditional Product Macro F1: 0,6762
SemEval ST1 Score: 0,6295

```
Train: 5082
Test: 997
Test columns: ['Unnamed: 0', 'year', 'month', 'day', 'country', 'title', 'text', 'hazard-category', 'product-category', 'hazard', 'product']
Hazard: accuracy=0.8175, macro F1=0.5827
Product: accuracy=0.7513, macro F1=0.6676
SemEval Hazard F1: 0.5827
SemEval Conditional Product F1: 0.6762
SemEval ST1 Test Score: 0.6295
Predictions saved to: /Users/w/Downloads/SPJ_Project/SPJ_cast_1/test_predictions.csv
```

vysledky testovania

Kód

1. Načíta tréningové a testovacie dáta z CSV a odstráni neúplné záznamy.
2. TF-IDF prevedie názvy správ na číselné príznaky.
3. Natrénuje dva klasifikátory logistickej regresie: riziko (C=1,0) a produkt (C=10,0).
4. Predpovie kategórie pre testovacie správy a pri dostupných štítkoch vypočíta Accuracy, Macro F1 a SemEval ST1.
5. Uloží predikcie do súboru test_predictions.csv.

Záver

Jednoduché riešenie s nízkymi výpočtovými nárokmi.
Zlepšenie oproti pôvodnému baseline o 0,1315 bodu.
Obmedzenia: iba krátke názvy správ a slabšie výsledky pri zriedkavých kategóriách.
Ďalší smer: kontextové modely, evolúcia modelu a porovnanie s existujúcimi riešeniami napríklad BERT.

Fakulta elektrotechniky a informatiky