SPJ: Projektová práca

SemEval 2025 Task 9: The Food Hazard Detection Challenge

Nikita Suhak, Denys Klym

Formulácia problému

V tejto úlohe riešime problém potravinových rizík na základe zadania SemEval-2025 Task 9, kde úlohou je klasifikácia textu a spočíva v tom, aby sme model naučili rozpoznávať typ rizika a kategóriu produktu, kvôli ktorej riziko vzniklo.

Úloha ma:

- Vstup v podobe textových správ o stiahnutí nebezpečných potravinových výrobkov z trhu
- Výstup: kategórie ohrozenia a produktu

Motivácia a ciele

Motiváciou a cieľom je, aby systém automaticky rozpoznával typ hrozieb, čím by sa urýchlil proces ich odhalenia a následného odstránenia. Motiváciou je ľudské zdravie a rýchlosť reakcie na ohrozenie zdravia.

Cieľom je preskúmať existujúce a potenciálne riešenia, vytvoriť základné riešenie, uskutočniť experimenty s existujúcimi riešeniami, porovnať výsledky a pokúsiť sa vylepšiť základné riešenie na základe meraní kvality.

Zdroje a existujúce riešenia

Hlavným zdrojom informácií bol vedecký článok organizátorov SemEval-2025 Task 9, oficiálna stránka súťaže a dostupné príklady implementácií.

V súťaži boli predstavené viaceré prístupy k riešeniu problému:

1. TF-IDF + Logistic Regression

Ide o jednoduchý prístup strojového učenia. Text sa najprv prevedie na číselné príznaky pomocou TF-IDF a následne sa použije logistická regresia na klasifikáciu.

- Výhodou je jednoduchá implementácia, rýchle trénovanie a nízke hardvérové nároky.
- Nevýhodou je, že model nemusí dobre rozpoznávať význam slov v rôznom kontexte.

2. BERT

BERT je model založený na architektúre Transformer. Dokáže lepšie pracovať s kontextom slov vo vetách.

- Výhodou je možnosť dosiahnuť lepšie výsledky pri spracovaní textu.
- Nevýhodou sú väčšie výpočtové nároky a zložitejšie trénovanie.

3. CICLe

CICLe je pokročilejší prístup využívajúci veľké jazykové modely a metódu conformal prediction. Jeho cieľom je zlepšiť klasifikáciu aj pri kategóriách s menším počtom príkladov.

Nevýhodou je vyššia zložitosť oproti tradičným metódam strojového učenia.

V našom projekte sme sa rozhodli začať s metódou TF-IDF a logistickou regresiou, vdaka jednoduchomu riešeniu, ktoré sa dá ľahko upravovať a porovnávať pri experimentoch.

Použitý dataset

Na trénovanie a testovanie sme použili dataset zo súťaže SemEval-2025 Task 9.

Dataset obsahuje celkovo 6644 záznamov, ktoré sú rozdelené na:

Trénovacie dáta	5082
Validačné dáta	565
Testovacie dáta	997

Jednotlivé záznamy obsahujú textové správy o potravinových rizikách a správne kategórie.

Pre naše riešenie sme použili tieto atribúty:

- title - názov alebo krátky text správy
- hazard-category - kategória potravinového rizika
- product-category - kategória produktu

Úlohou modelu je na základe textu predpovedať dve kategórie. Dataset obsahuje 10 kategórií rizík a 22 kategórií produktov.

Rozdelenie kategórií nie je rovnomerné. Niektoré kategórie obsahujú veľký počet príkladov, zatiaľ čo iné sa vyskytujú len zriedkavo. Tento problém môže negatívne ovplyvniť kvalitu klasifikácie.

Baseline riešenie

Ako základné riešenie sme použili sme knižnice pandas, NumPy a scikit-learn.

Naším cieľom bolo najprv vytvoriť jednoduchý funkčný model a následne skúmať možnosti jeho zlepšenia.

Princíp riešenia:

Text -> TF-IDF -> Logistic Regression -> Predikcia kategórií

Použili sme dva samostatné klasifikátory logistickej regresie:

- Prvý model predpovedá kategóriu rizika.
- Druhý model predpovedá kategóriu produktu.

Oba modely využívajú rovnaké textové príznaky získané pomocou TF-IDF.

Príprava dát

Najprv sme načítali dataset zo súboru CSV pomocou knižnice pandas. V prvej fáze sme rozdelili trénovací dataset na dve časti. Vzniklo rozdelenie:

- Trénovanie: 4062 záznamov
- Validácia: 1020 záznamov

Neskôr sme prešli na oficiálne rozdelenie datasetu zo súťaže.

TF-IDF

Na prevod textu na číselné hodnoty sme použili TfidfVectorizer.

TF-IDF hodnotí dôležitosť slov na základe ich výskytu v dokumente a v celom datasete.

Na trénovacích dátach sme použili metódu fit_transform(), ktorá vytvorila slovník a prevedla texty na číselné vektory.

Na validačných dátach sme použili iba transform(), aby sme zabránili využitiu informácií z validačných dát pri vytváraní slovníka.

Logistic Regression

Na klasifikáciu sme použili algoritmus logistickej regresie.

Model sa učí na číselných príznakoch vytvorených pomocou TF-IDF a na správnych kategóriách z datasetu.

Na začiatku sme použili štandardné nastavenia a parameter max_iter=1000.

Po natrénovaní sme pomocou metódy predict() získali predpovede pre validačné dáta.

Experimenty a výsledky

Pri experimentoch sme skúmali, ako rôzne nastavenia TF-IDF a logistickej regresie ovplyvňujú výsledky.

Použili sme metriky Accuracy a Macro F1.

Accuracy vyjadruje podiel správne klasifikovaných záznamov. Macro F1 hodnotí jednotlivé kategórie samostatne a následne vypočíta ich priemer. Táto metrika je dôležitá najmä pri nevyváženom datasete.

Najprv sme použili štandardný TfidfVectorizer() a logistickú regresiu s C=1.0 bez vyvažovania tried.

Výsledky:Model dosiahol pomerne dobrú celkovú presnosť, ale Macro F1 bolo výrazne nižšie.

Potom sme zmenili parametre TF-IDF:

ngram_range=(1, 2)

sublinear_tf=True

Model tak využíval jednotlivé slová aj dvojice slov. Parameter sublinear_tf zároveň zmenil spôsob výpočtu frekvencie slov pomocou logaritmu.

Macro F1 pri rizikách sa mierne zvýšilo, ale výsledky klasifikácie produktov sa zhoršili.

Potom sme použili:

ngram_range=(1, 2)

Parameter sublinear_tf sme vrátili na predvolenú hodnotu.Výsledky ukázali, že samotné pridanie bigramov neprinieslo zlepšenie oproti pôvodnému modelu.

Následne sme použili štandardné unigram a nastavili:

sublinear_tf=True

Upravili logistickú regresiu pomocou parametra:

class_weight="balanced"

Tento parameter zohľadňuje nerovnomerný počet príkladov v jednotlivých kategóriách.V porovnaní so základným modelom došlo k výraznému zlepšeniu Macro F1.

Pri rizikách sa hodnota zvýšila z 0,4516 na 0,6009 a pri produktoch z 0,3886 na 0,5082.

Presnosť klasifikácie produktov mierne klesla, ale výsledky Macro F1 boli výrazne lepšie.

Následne sme skúmali parameter C pri logistickej regresii.

Parameter C ovplyvňuje silu regularizácie modelu. Menšia hodnota znamená silnejšiu regularizáciu, zatiaľ čo väčšia hodnota znamená slabšiu regularizáciu.

Testovali sme tri hodnoty: 0.1, 1.0 a 10.0.

Vo všetkých prípadoch sme použili class_weight="balanced".

C	Hazard Accuracy	Hazard Macro F1	Product Accuracy	Product Macro F1
0.1	0,7637	0,5539	0,5206	0,3761
1.0	0,8049	0,6009	0,6608	0,5082
10.0	0,8275	0,5945	0,7324	0,5373

Pri kategóriách rizík sme dosiahli najlepší Macro F1 pri C=1.0.

Pri kategóriách produktov sme dosiahli najlepší Macro F1 pri C=10.0.

Model sme trénovali na 5082 záznamoch. Použili sme TF-IDF so štandardnými parametrami a dva klasifikátory logistickej regresie s vyvážením tried.

Použité nastavenia:

- Hazard: class_weight="balanced", C=1.0
- Product: class_weight="balanced", C=10.0
- max_iter=1000 pre oba klasifikátory

Výsledky finálneho testovania:

Metrika	Kategória rizika	Kategória produktu
Accuracy	0,8175	0,7513
Macro F1	0,5827	0,6676

Oficiálna metrika ST1:

Metrika	Hodnota
Hazard Macro F1	0,5827
Conditional Product Macro F1	0,6762
SemEval ST1 Score	**0,6295**

Na validačných dátach sme dosiahli ST1 Score 0,6648 a na testovacích dátach 0,6295. Rozdiel môže byť spôsobený odlišným rozložením a náročnosťou príkladov.

Následne sme náš výsledok porovnali s publikovanými výsledkami súťaže SemEval-2025.Naše riešenie dosiahlo vyššie skóre ako pôvodný baseline s TF-IDF a logistickou regresiou. Rozdiel predstavuje 0,1315 bodu.

Nedosiahli sme výsledky najlepších pokročilých modelov, ale ukázali sme, že aj jednoduchý klasifikačný systém môže dosiahnuť použiteľné výsledky.

Za najdôležitejšie zlepšenie považujeme použitie vyvažovania tried a samostatné nastavenie parametra C pre oba klasifikátory.

Výhodou nášho riešenia je jednoduchá implementácia a nízka výpočtová náročnosť. Obmedzením je používanie iba krátkych názvov správ a slabšie rozpoznávanie niektorých menej zastúpených kategórií. Výsledky na testovacích dátach používame ako finálne hodnotenie zvolenej konfigurácie, nie na ďalšie nastavovanie modelu.

Použitá literatúra

1. Randl, K., Pavlopoulos, J., Henriksson, A., Lindgren, T., Bakagianni, J. (2025). *SemEval-2025 Task 9: The Food Hazard Detection Challenge*. Proceedings of the 19th International Workshop on Semantic Evaluation, s. 2523–2534. https://aclanthology.org/2025.semeval-1.325/
2. SemEval-2025 Task 9. *The Food Hazard Detection Challenge – Official Website*. https://food-hazard-detection-semeval-2025.github.io/
3. SemEval-2025 Task 9. *Official GitHub Repository*. https://github.com/food-hazard-detection-semeval-2025/food-hazard-detection-semeval-2025.github.io

Použitie LLM

Hlavnou LLM, ktorá bola použitá, bol model ChatGPT 6.1 Sol Medium, ktorý slúžil predovšetkým ako pomocník pri formulovaní úlohy a usporiadaní údajov.

Hlavné úlohy umelej inteligencie:
- Analýza literatúry a vyhľadávanie
- Vysvetľovanie metód v jazyku Python
- Oprava chýb
- Pomoc v spracovani dat a popis vývoja
- Osobitná poznámka o AI-prekladači pre väčšie pohodlie

Relevantné a užitočné využitie LLM, výzvy a výsledky budú opísané v samostatnej prílohe.