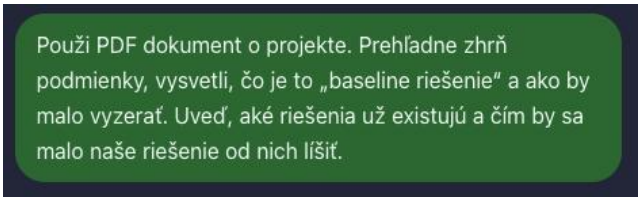
SPJ: Použitie LLM



Čo je baseline riešenie

Baseline je východiskové funkčné riešenie, s ktorým porovnávame neskoršie úpravy. Ukazuje, akú kvalitu možno dosiahnuť zrozumiteľným štandardným postupom.

Pre nás je vhodný napríklad tento variant:

Text správy → TF-IDF → klasifikátory → kategória nebezpečenstva a kategória produktu.

TF-IDF prevedie text na číselné príznaky a klasifikátory sa naučia spájať tieto príznaky so správnymi kategóriami. Môžeme použiť logistickú regresiu — hotový algoritmus z knižnice pre Python. Napriek svojmu názvu sa používa na klasifikáciu.

Ako má baseline vyzerať pri odovzdaní prvej etapy

Potrebujeme tri prepojené časti:

- **Kód:** načíta dáta, natrénuje model, vytvorí predikcie a vypočíta kvalitu.
- **Výsledky:** tabuľku s dosiahnutými hodnotami metrík a stručnú analýzu chýb.
- **Opis:** použité dáta a nastavenia, zdôvodnenie výberu metódy a návod na spustenie.

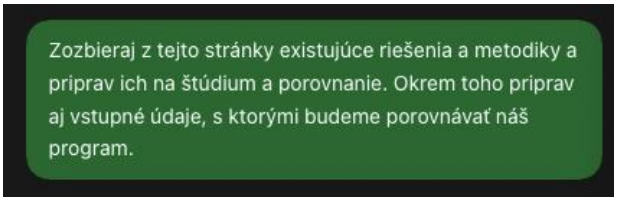
Grafické rozhranie nie je uvedené medzi povinnými požiadavkami. Pre baseline stačí spustenie z PyCharmu alebo príkazového riadka.

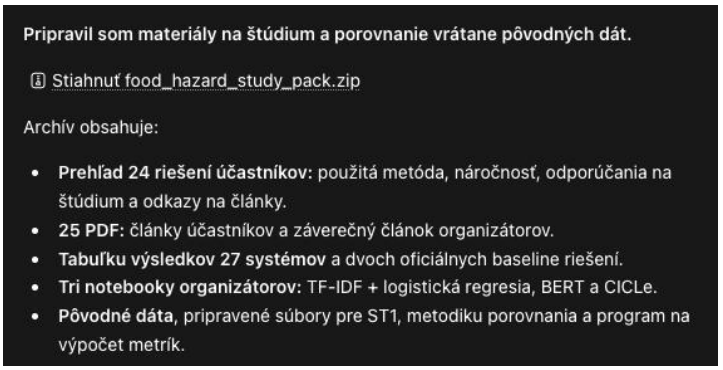
Aké riešenia už existujú

Pre túto úlohu boli publikované jednoduché metódy aj zložité neurónové systémy:

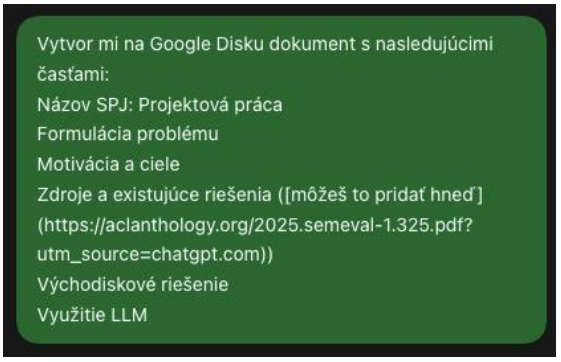
Práca	Použité riešenie
Anaselka	Reprezentácie BoW a TF-IDF, klasifikátory SVM a naivný Bayes, ladenie parametrov. Tento klasický prístup je blízky tomu, čo môžeme zvládnuť aj my. aclanthology.org
CICL	Porovnávali LinearSVC, Random Forest a LightGBM s modelmi BERT a ModernBERT; skúmali učenie pri nevyvážených triedach. aclanthology.org
BitsAndBites	Použili LLM na extrakciu informácií a postupnú predikciu najprv všeobecných a potom podrobnejších označení. aclanthology.org
MyMy	Rozširovali trénovacie dáta pomocou externých znalostí z PubMed a RAG, pričom venovali pozornosť zriedkavým kategóriám. aclanthology.org

Vysledok: podrobná analýza existujúcich riešení, definícia zadaného problému, podmienky na splnenie úlohy





Záver: zhromažďovanie analytických údajov, datasetov a zdrojov na učenie



Automatizácia bežných procesov

Skontroluj kód, či v ňom nie sú chyby, ktoré som si možno nevšimol

Kód nemá zjavné syntaktické chyby a základný postup učenia je správny. Našiel som však niekoľko miest, ktoré môžu spôsobiť problémy pri vyhodnotení alebo odovzdávaní výsledkov.

Ide o kontrolu vloženého kódu. Trénovanie som nespúšťal a obsah tvojho `train_1.csv` z neho neviem overiť.

1. Chýba použitie validačných dát.

Program sa učí na `train_1.csv` a následne sa vyhodnocuje priamo na `incidents_test.csv`. To je v poriadku pri záverečnom teste už vybraného riešenia. Problém by vznikol, keby ste podľa testového skóre opakovane menili `C`, `class_weight` alebo nastavenia TF-IDF.

3. Treba overiť zachovanie identifikátorov.

Tu môže vzniknúť problém:

Python Запустить

```python
'id': test['id'] if 'id' in test.columns else test.index
```

Ak CSV obsahuje pôvodné identifikátory v inom stĺpci, program ich ignoruje a použije index tabuľky.

V predtým stiahnutom oficiálnom súbore mal prvý stĺpec prázdny názov; pri bežnom načítaní cez pandas sa takýto stĺpec označuje napríklad ako `Unnamed: 0`.

pandas 3.1.0 doc...

Ak má aj váš súbor tento formát, môžete po načítaní použiť:

Python Запустить

```python
if 'id' not in test.columns and 'Unnamed: 0' in test.columns:
    test = test.rename(columns={'Unnamed: 0': 'id'})
```

Potom overte, že `id` neobsahuje prázdne ani duplicitné hodnoty. Použitie `test.index` nemusí byť chybné, ale treba vedieť, že zodpovedá očakávaným identifikátorom — nie to iba predpokladať.

Záver: kontrola kódu, riešenie problémov, vyčistenie projektu